

Анализ номинативных данных

Кто чаще обращается в службу знакомств: мужчины или женщины?

Зависит ли количество аварий на производстве от дня недели?

Можно ли утверждать, что водители-женщины чаще становятся участниками ДТП (дорожно-транспортных происшествий)?

Можно ли утверждать, что выигрыши в игре распределены не случайно среди проигравших?

| | Распределение: | |
|----------|----------------|---------------|
| | эмпирическое | теоретическое |
| «За» | 30 | 25 |
| «Против» | 20 | 25 |
| Сумма: | 50 | 50 |

Хи-квадрат

$$\chi^2_{\text{э}} = \sum_{i=1}^P \frac{(f_{\text{э}} - f_{\text{т}})^2}{f_{\text{т}}}$$

```
import org.apache.spark.ml.linalg.{Vector, Vectors}
import org.apache.spark.ml.stat.ChiSquareTest

val data = Seq(
  (0.0, Vectors.dense(0.5, 10.0)),
  (0.0, Vectors.dense(1.5, 20.0)),
  (1.0, Vectors.dense(1.5, 30.0)),
  (0.0, Vectors.dense(3.5, 30.0)),
  (0.0, Vectors.dense(3.5, 40.0)),
  (1.0, Vectors.dense(3.5, 40.0))
)

val df = data.toDF("label", "features")
val chi = ChiSquareTest.test(df, "features", "label").head
println("pValues = " + chi.getAs[Vector](0))
println("degreesOfFreedom = " + chi.getSeq[Int](1).mkString("[", ",", "])")
println("statistics = " + chi.getAs[Vector](2))
```

Непараметрические методы

U - Манна - Уитни

Обозначим значения переменной для одной выборки X , а для другой выборки — Y и упорядочим значения обеих выборок по возрастанию.

| | | | | | | | | | | | | | | | | |
|----------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| Значения | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 19 |
| Выборка | X | X | Y | X | X | X | Y | X | X | Y | X | Y | Y | Y | Y | Y |

$$U_x = mn - R_x + \frac{n(n+1)}{2},$$

$$U_y = mn - R_y + \frac{m(m+1)}{2},$$

$$U_x + U_y = mn,$$

| | | | | | | | | | | | | | | | | | |
|---|----------|---|---|---|---|---|---|---|----|----|----|----|----|----|----|----|----|
| 1 | Значения | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 19 |
| 2 | Выборка | X | X | Y | X | X | X | Y | X | X | Y | X | Y | Y | Y | Y | Y |
| 3 | Ранги | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 |
| 4 | Ранги X | 1 | 2 | | 4 | 5 | 6 | | 8 | 9 | | 11 | | | | | |
| 5 | Ранги Y | | | 3 | | | | 7 | | | 10 | | 12 | 13 | 14 | 15 | 16 |

Шаг 1. Значения двух выборок объединяются в один ряд, упорядоченный в порядке возрастания или убывания. Обозначается принадлежность каждого значения к той и другой выборке (строки 1 и 2).

Шаг 2. Значения выборок ранжируются, и выписываются отдельно ранги для одной и другой выборки (строки 3–5).

Шаг 3. Вычисляются суммы рангов по $X(R_x)$ и по $Y(R_y)$: $R_x = 46$; $R_y = 90$.

Шаг 4. Вычисляются U_x и U_y по формуле 12.1:

$$U_x = 8 \cdot 8 - 46 + \frac{8(8+1)}{2} = 54, \quad U_y = 8 \cdot 8 - 90 + \frac{8(8+1)}{2} = 10, \quad U_x + U_y = 64 = mn.$$

Шаг 5. Определяется p -уровень значимости: наименьшее из U сравнивается с табличным (приложение 9) для соответствующих объемов выборки $m = 8$ и $n = 8$. Значение $p \leq 0,05$ ($0,01$), если вычисленное $U_{\text{эмп.}} \leq U_{\text{табл.}}$. В нашем случае наименьшим является $U_y = 10$, которое и принимается за эмпирическое значение критерия. Оно меньше критического для $p = 0,05$ ($U = 13$), но больше критического для $p = 0,01$ ($U = 7$). Следовательно, $p < 0,05$.

T - Вилкоксон

Проверим гипотезу о различии значений показателя, измеренного дважды на одной и той же выборке («Условие 1» и «Условие 2»), на уровне $\alpha = 0,05$:

| | | | | | | | | | | | | | |
|---|-------------------|-----|----|----|----|----|----|----|----|-----|----|------|------|
| 1 | № объекта: | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
| 2 | Условие 1: | 6 | 11 | 12 | 8 | 5 | 10 | 7 | 6 | 3 | 9 | 4 | 5 |
| 3 | Условие 2: | 14 | 5 | 8 | 10 | 14 | 7 | 12 | 13 | 11 | 10 | 15 | 16 |
| 4 | Разность d_i : | -8 | 6 | 4 | -2 | -9 | 3 | -5 | -7 | -8 | -1 | -11 | -11 |
| 5 | Ранги $ d_i $: | 8,5 | 6 | 4 | 2 | 10 | 3 | 5 | 7 | 8,5 | 1 | 11,5 | 11,5 |
| 6 | Ранги $d_i (+)$: | | 6 | 4 | | | 3 | | | | | | |
| 7 | Ранги $d (-)$: | 8,5 | | | 2 | 10 | | 5 | 7 | 8,5 | 1 | 11,5 | 11,5 |

Шаг 1. Подсчитать разности значений для каждого объекта выборки (строка 4).

Шаг 2. Ранжировать абсолютные значения разностей (строка 5).

Шаг 3. Выписать ранги положительных и отрицательных значений разностей (строки 6 и 7).

Шаг 4. Подсчитать суммы рангов отдельно для положительных и отрицательных разностей: $T_1 = 13$; $T_2 = 65$. За эмпирическое значение критерия $T_{\text{эмп}}$ принимается меньшая сумма: $T_{\text{эмп}} = 13$.

Шаг 5. Определяется p -уровень значимости: $T_{\text{эмп}}$ сравнивается с табличным (приложение 10) для соответствующего объема выборки. Значение $p \leq 0,05$ (0,01), если вычисленное $T_{\text{эмп}} \leq T_{\text{табл}}$. В нашем случае эмпирическое значение равно критическому значению для $p = 0,05$. Следовательно, $p = 0,05$.

Экспериментальные планы

AB

ABn

$$1 - (1 - \alpha)^m,$$

$m = 5, \alpha = 0,05$ она равна $\approx 22,6\%$

Поправка Бонферрони

$$p_i < \alpha/m$$

AABB

$A-A+B-B+$

Многорукие бандиты



Биномиальное распределение

$$f(k, n, p) = \Pr(k; n, p) = \Pr(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Бернулли

$$f_a(y \mid \theta_a) = \theta_a^y (1 - \theta_a)^{1-y},$$

$$\theta_i \sim \text{Beta}(\alpha_i, \beta_i)$$

$$y_i \sim \text{Bernoulli}(\theta_i)$$

модель легко интерпретируема, α — это количество успешных испытаний, а β — количество неуспешных испытаний; среднее значение будет $\frac{\alpha}{\alpha+\beta}$.